



PageIndex

Vectorless, Reasoning-based RAG

许宇鸿

计算机科学与工程学院

2026 年 4 月 19 日

- 1 研究背景
- 2 PageIndex 框架
- 3 PathTracer: 执行路径追踪
- 4 实验与应用
- 5 部署与应用场景
- 6 总结与展望



研究背景：传统 RAG 的局限

- 传统向量检索依赖**语义相似度**而非真正的相关性
- 向量化需要 Chunking（分块），破坏文档原有结构
- 长文档场景下检索精度不足，缺乏可解释性
- 专业领域文档（金融、法律、学术）需要**多步推理**才能找到关键信息

核心洞察：Similarity $\neq$ Relevance — 真正的检索需要推理能力



PageIndex: 无向量、基于推理的 RAG

受 AlphaGo 启发, PageIndex 提出了一种全新的检索范式:

- 1 树结构索引:** 将长文档转化为层次化的”目录”树
- 2 推理式检索:** 利用 LLM 在树结构上进行推理式搜索
- 3 类人检索:** 模拟人类专家浏览和提取知识的方式

核心特点

- 无需向量数据库 (No Vector DB)
- 无需分块处理 (No Chunking)
- 更好的可解释性与可追溯性



Step 1: 树结构索引生成

- 解析 PDF 文档，生成层次化树索引
- 每个节点包含标题、页码范围、摘要

Step 2: 推理式树搜索

- LLM 在树结构上进行逐层推理
- 根据问题语义选择最相关的分支
- 返回精确的页码和段落引用



JSON 结构

```
{
  "title": "Financial Stability",
  "node_id": "0006",
  "start_index": 21,
  "end_index": 22,
  "summary": "The Federal Reserve ...",
  "nodes": [
    {
      "title": "Monitoring ...",
      "node_id": "0007",
      "start_index": 22,
      "end_index": 28
    },
    {
      "title": "Cooperation ...",
      "node_id": "0008",
      "start_index": 28,
      "end_index": 31
    }
  ]
}
```

树结构索引示例

节点属性

- title: 章节标题
- node_id: 唯一标识
- start/end_index: 页码范围
- summary: 内容摘要
- nodes: 子节点列表



PathTracer: 代码执行路径追踪与覆盖率分析

项目中的 pathtracer 模块, 用于追踪 Python 程序的执行路径:

- **分支追踪**: 记录 if/else/for/while/try 等分支的执行情况
- **函数调用链**: 记录函数调用的深度、参数和返回值
- **覆盖率报告**: 生成 HTML/JSON/文本格式的覆盖率报告

使用示例

```
python -m pathtracer.cli agent_pageindex.py --query "... " --doc-top-k 3
```



基于 PageIndex 构建的 Mafin 2.5 系统在 FinanceBench 上达到 98.7% 准确率：

系统	准确率
Mafin 2.5 (PageIndex)	98.7%
传统向量 RAG	< 80%

- 在金融报告、SEC 文件等专业文档上表现优异
- 层次化索引 + 推理式检索 = 精准定位关键信息





部署方式

- **本地部署**: 开源代码自托管
- **云服务**: Chat Platform / MCP / API
- **企业版**: 私有化部署

应用场景

- 金融报告分析
- 法律文件检索
- 学术论文问答
- 技术文档导航

PageIndex 的核心贡献:

- 1 提出**无向量、基于推理**的 RAG 新范式
- 2 设计层次化**树结构索引**，保留文档原有结构
- 3 在 FinanceBench 上实现 SOTA 性能

未来方向:

- 支持更多文档格式 (Word、PPT 等)
- 多模态文档理解 (图表、公式)
- 更细粒度的推理与检索策略



谢谢!

